

Notas suplementares e capturas de telas complementares ao documento principal README.md que contém todas as análises e descritivo de procedimentos.

<https://github.com/literaturaandre-byte/mvp-literatura-sul-global-databricks>

<https://dbc-107c5e90-d6b6.cloud.databricks.com/dashboardsv3/01f1bae0b9e81114bf3c7aae5df133e9/published?o=7474652075507820>

Autor(a) canônico(a)	Wikidata	IDs Open Library que serão extraídos	Regra de consolidação
Adriana Lisboa	Q4263049	OL1527013A	Um perfil
Ana Maria Gonçalves	Q16489985	OL12217460A	Um perfil
Bernardo Carvalho	Q822971	OL6495716A	Um perfil
Carola Saavedra	Q6538113	OL5697446A	Um perfil
Conceição Evaristo	Q16939999	OL8701565A, OL5122048A, OL2940871A	Consolidar por work_id; controle auxiliar por título normalizado + ano
Geovani Martins	Q51882320	OL7633883A	Um perfil
Itamar Vieira Junior	Q59309236	OL9081057A	Um perfil
Jeferson Tenório	Q112730259	OL13513413A, OL11730977A, OL10432462A	Consolidar por work_id; controle auxiliar por título normalizado + ano
Julián Fuks	Q10312919	OL5533173A	Um perfil
Milton Hatoum	Q465693	OL718270A	Um perfil

Estrutura de dados esperada da coleta produzirá arquivos brutos separados por fonte e entidade da seguinte maneira:

data/

├── bronze/

| ├── wikidata/

| | └── authors_wikidata.csv

| └── openlibrary/

| ├── authors/

| | └── author_profile_<openlibrary_author_id>.json

```
|   |— works/
|   |   |— author_works_<openlibrary_author_id>.json
|   |— editions/
|   |   |— work_editions_<openlibrary_work_id>.json
|   |— ratings/
|       |— work_ratings_<openlibrary_work_id>.json
```

Contexto de Negócio e Perguntas (Etapas 2 e 4.1).

O estudo investiga, em um recorte exploratório, fatores bibliográficos e editoriais associados à visibilidade de obras literárias de autores brasileiros no século XXI, entendendo o Brasil como parte do Sul Global. O problema original — compreender quais fatores influenciam a escolha de livros de literatura no Sul Global — é mais amplo do que os dados disponíveis permitem observar diretamente. Por isso, o MVP emprega indicadores indiretos e agregados de visibilidade, tais como número de edições, diversidade de idiomas e avaliações agregadas. A análise não pretende demonstrar causalidade sobre escolhas individuais de leitores, mas identificar padrões de circulação editorial, disponibilidade linguística e recepção agregada no recorte selecionado.

Fontes e licença dos dados.

O estudo utiliza dados estruturados de duas fontes abertas. O Wikidata foi empregado para constituir e documentar a dimensão de autores, com identificadores estáveis, nomes, cidadanias, ocupações e ligações externas. Seus dados estruturados são disponibilizados sob a licença Creative Commons Zero (CC0 1.0). A Open Library foi utilizada para coletar metadados bibliográficos de autores, obras e edições — incluindo títulos, datas, idiomas, editoras, assuntos e métricas agregadas disponíveis. A extração foi limitada a 14 identificadores de autor associados a 10 autores brasileiros selecionados intencionalmente. Não foram utilizados textos integrais de obras, perfis de usuários, comentários individuais ou outros dados pessoais. A coleta foi realizada por APIs públicas de baixo volume, respeitando a recomendação da Open Library e reservar dumps mensais para acesso em massa.




Fig. Carga dos Dados; Versionamento e integração no ambiente de desenvolvimento (Databricks-gitfolder).






Fig. Organização do projeto e versionamento.



The screenshot shows a Jupyter Notebook with a file explorer on the left and a code cell on the right. The file explorer shows a directory structure with files like `config.py`, `extract_openlibrary.py`, `.gitignore`, `LICENSE`, and `README.md`. The code cell displays a table with the following data:

	source_url	author_name	author_key
1	https://openlibrary.org/authors/OL1527013A.js...	Adriana Lisboa	/authors/OL1527013A

Below the table, it indicates "1 row" and "1.697s runtime". To the right of the table, a list of Open Library IDs is shown:

- OK: OL1527013A
- OK: OL12217460A
- OK: OL6495716A
- OK: OL5697446A
- OK: OL8701565A
- OK: OL5122048A
- OK: OL2940871A
- OK: OL7633883A
- OK: OL9081057A
- OK: OL13513413A
- OK: OL11730977A
- OK: OL10432462A
- OK: OL5533173A
- OK: OL718270A

At the bottom, it states "Autores extraídos: 14" and "Respostas de obras extraídas: 14".

The screenshot shows a Jupyter Notebook with a file explorer on the left and a code cell on the right. The file explorer shows a directory structure with files like `config.py`, `extract_openlibrary.py`, `.gitignore`, `LICENSE`, and `README.md`. The code cell displays a raw JSON preview of Open Library works. The preview shows the following structure:

```

{
  "links": {
    "self": "/authors/OL10432462A/works.json?limit=100",
    "author": "/authors/OL10432462A",
    "size": 1,
    "entries": [
      {
        "title": "O aves..."
      }
    ]
  }
}

```

The preview indicates "5 rows" and "2.170s runtime".

Tabela	Papel	Registros esperados
workspace.default.bronze_wikidata_authors_raw	Resultado bruto da consulta SPARQL de autores	42
workspace.default.bronze_openlibrary_authors_raw	Perfis JSON brutos dos 14 IDs de autores	14
workspace.default.bronze_openlibrary_works_raw	Respostas JSON brutas de obras para os 14 IDs	14

Qualidade de Dados

A autora Conceição Evaristo aparece em três registros distintos na Open Library, derivados de variações de nome e de normalização de caracteres: OL8701565A, OL5122048A e OL2940871A. Como nenhum dos registros concentrou integralmente as obras relevantes, foram extraídos dados das três chaves. Na transformação Silver, as obras foram consolidadas por `work_id`; quando necessário, uma chave auxiliar formada por título normalizado e ano de primeira publicação será usada para identificar potenciais duplicações. Essa medida reduz duplicidade sem alterar a preservação dos dados brutos na camada Bronze.

Tabela	Granularidade	Linhas	Uso principal
gold_work_edition_profile	Uma linha por obra	82	Perfil de idiomas, número de edições e período de publicação
gold_work_publication_profile	Uma linha por obra	82	Diversidade de editoras e locais por obra
gold_language_distribution	Um idioma	6	Gráfico de distribuição linguística
gold_publication_year_distribution	Um ano	33	Linha ou barras por ano de publicação
gold_publisher_distribution	Uma editora	67	Ranking de editoras
gold_publish_place_distribution	Um local	34	Ranking de locais de publicação

Foram identificados perfis autorais fragmentados na Open Library para Conceição Evaristo e Jeferson Tenório. Contudo, na extração realizada, não foram encontradas chaves de obra duplicadas entre as 82 relações obra–perfil coletadas. A deduplicação por work_id foi aplicada preventivamente e preservou 82 obras únicas.

Dos 82 títulos analisados, 34 apresentam ao menos um sinal catalogado de circulação internacional: 20 possuem edição em inglês, 24 possuem edição com local editorial internacional e 10 combinam os dois critérios. O indicador é exploratório e não mede exaustivamente traduções, disponibilidade comercial ou circulação de leitores; ele resume somente os metadados recuperados da Open Library para o corpus.

Dashboard Final

